

โครงสร้างพื้นฐาน AI ด้านข้อมูลสำหรับธุรกิจ

นี่คือเวอร์ชันเว็บไซต์ของ playbook ที่ถูกเขียนใหม่ให้เหมาะกับการอ่านบนเว็บ ครอบคลุมตั้งแต่การวาง data foundation, การออกแบบ dashboard ไปจนถึง AI agent ที่เชื่อมกับบริบทธุรกิจจริง

ครอบคลุม: DATA ARCHITECTURE · ETL · WAREHOUSE · DASHBOARD · AI AGENT · DEPLOYMENT

THCLOUD.AI BLUEPRINT

คู่มือฉบับเว็บที่จัดวางเหมือน playbook จริง

อ่านเป็นลำดับตั้งแต่ data foundation ไปจนถึง AI agent หรือข้ามไปยัง section ที่ตรงกับสถานะของธุรกิจคุณได้ทันที



THCloud.AI



Data Foundation

audit, schema design, ingestion strategy และ data quality check ที่วางถูกตั้งแต่ต้น



Dashboard & KPI

ออกแบบ dashboard โดยเริ่มจากการตัดสินใจของทีม ไม่ใช่เริ่มจากรายชื่อ metric



AI Agent

แยกให้ชัดว่าเมื่อไหร่ควรใช้ RAG, เมื่อไหร่ควรใช้ tool call และจะ deploy อย่างไรให้เชื่อถือได้

วิธีใช้คู่มือนี้ให้ได้ประโยชน์สูงสุด

คู่มือฉบับนี้ไม่ใช่เอกสารขายสินค้า แต่เป็นคู่มืออ้างอิงจริงสำหรับการวาง AI data infrastructure ให้ใช้งานได้จริงในธุรกิจที่มีหลายช่องทาง หลายทีม และหลายแหล่งข้อมูล

คุณไม่จำเป็นต้องอ่านแบบเรียงหน้าเสมอไป ถ้าคุณอยู่ในช่วงเริ่มต้น ให้โฟกัส Data Foundation ก่อน ถ้ามี dashboard แล้วแต่ AI ยังไม่ตอบโจทย์ ให้ข้ามไปดูส่วน Analytics Layer และ AI Agent ได้ทันที

ยังไม่มีระบบข้อมูลกลาง

เริ่มจาก Data Foundation เพื่อออกแบบ schema, audit แหล่งข้อมูล, และวาง ingestion ให้ถูกต้องตั้งแต่ต้น

มีข้อมูล แต่ dashboard ยังไม่ตอบคำถาม

โฟกัส Analytics Layer โดยเริ่มจากการตัดสินใจที่ทีมต้องทำทุกวัน ไม่ใช่เริ่มจาก metric ที่มีอยู่

มี dashboard แล้ว อยากเพิ่ม AI

ไปที่ส่วน AI Agent เพื่อแยกให้ชัดว่าเมื่อไหร่ควรใช้ RAG และเมื่อไหร่ควรใช้ tool calling กับข้อมูลสด

กำลังเลือกเครื่องมือ

อ่านส่วน Tech Stack และ Roadmap เพื่อมอง trade-off ระหว่าง open-source, SaaS และลำดับการติดตั้งแต่ละเฟส

ทำไม AI ส่วนใหญ่ถึงใช้ไม่ได้ผลจริง

ธุรกิจส่วนใหญ่ไม่ได้พลาดเพราะโมเดล AI ไม่เก่ง แต่พลาดเพราะลำดับการวางระบบผิด ทำให้ AI ไปอยู่บนข้อมูลที่กระจัดกระจาย ล้าสมัย หรือไม่มีโครงสร้างพอให้ใช้งานจริง

CORE PRINCIPLE

ลำดับที่ถูกต้องคือ Data Foundation ก่อน → Analytics Layer ถัดมา → AI Interface เป็นขั้นสุดท้าย

เริ่มจาก Interface ก่อน

การซื้อ chatbot หรือ AI assistant ก่อนที่ข้อมูลจะสะอาดและรวมเป็นหนึ่ง จะทำให้ demo ดูดีแต่ใช้งานจริงไม่ได้ เพราะคำตอบจะดึงจากข้อมูลไม่ครบหรือไม่ทันเหตุการณ์

รวมข้อมูลโดยไม่ Normalise

การย้ายข้อมูลทุกอย่างมาไว้ใน warehouse เดียวไม่ได้แปลว่าข้อมูลพร้อมใช้ ถ้าแต่ละช่องทางใช้คำเรียก รายละเอียด และ grain ต่างกัน คุณแค่รวมความสับสนไว้ที่เดียว

Engineering มากเกินไป

การออกแบบเพื่อรองรับทุก use case ตั้งแต่วันแรก มักทำให้ pipeline ซับซ้อนเกินไป schema نامธรรมเกินไป และ dashboard ตอบคำถามที่ไม่มีใครถามจริง

มอง AI เป็น Product ไม่ใช่ Layer

AI tool เป็นเพียง interface ส่วน intelligence ที่ใช้งานได้จริงเกิดจากการเชื่อม AI เข้ากับ warehouse, dashboard และเครื่องมือธุรกิจที่มีข้อมูลสดและเชื่อถือได้

การออกแบบ Data Foundation

Data Foundation คือทุกอย่างที่อยู่ใต้ dashboard และ AI agent: ข้อมูลอยู่ที่ไหน มาอย่างไร สดแค่ไหน และถูกนิยามอย่างไร ถ้าทำส่วนนี้ถูกต้อง layer ด้านบนจะเสถียร ถ้าทำผิดคุณจะต้อง rebuild หลายรอบ

เริ่มจากการ audit ข้อมูลที่มีอยู่จริงก่อนเขียน pipeline แม้แต่บรรทัดเดียว เพราะการรู้แหล่งข้อมูล เจ้าของข้อมูล และความถี่การเปลี่ยนแปลง คือสิ่งที่กำหนด design ทั้งหมด

AUDIT QUESTIONS

- ✓ ข้อมูลอยู่ที่ไหน และเชื่อมต่อผ่าน API, export, webhook หรือ manual ได้อย่างไร
- ✓ ข้อมูลอยู่ในรูปแบบ JSON, CSV, database table หรือไฟล์ที่ต้องแปลงก่อน
- ✓ ข้อมูลเปลี่ยนบ่อยแค่ไหน เพื่อกำหนดความถี่การ sync ที่เหมาะสม
- ✓ ใครเป็นเจ้าของข้อมูล และใครอนุมัติการเข้าถึงเมื่อมีปัญหา
- ✓ ยังขาดข้อมูลอะไรอยู่บ้างที่จำเป็นต่อ dashboard หรือ AI use case ในอนาคต

1. Audit ข้อมูลทุกแหล่ง

ตอบให้ได้ว่าข้อมูลอยู่ที่ไหน อยู่ใน format อะไร เปลี่ยนบ่อยแค่ไหน ใครเป็นเจ้าของ และยังขาดอะไรอยู่บ้างก่อนเริ่มเชื่อมต่อ

2. ออกแบบ Schema ก่อน Ingest

กำหนด vocabulary, entity หลัก, grain และ primary key ให้ชัดเจน เพื่อไม่ต้องย้อนแก้ dashboard, query และ AI agent ภายหลัง

3. เลือกสถาปัตยกรรม Ingestion ให้เหมาะสม

แยกให้ชัดว่าแหล่งไหนควรใช้ API แบบ incremental, แหล่งไหนใช้ scheduled export และแหล่งไหนควรใช้ manual upload พร้อม template

4. วาง Data Quality Check ตั้งแต่วันแรก

Row count validation, null checks, freshness monitoring และ reconciliation กับ source data ต้องอยู่ใน pipeline ตั้งแต่วันแรก ไม่ใช่เพิ่มทีหลังเมื่อ dashboard เริ่มผิด

Data Quality ต้องอยู่ใน pipeline ตั้งแต่วันแรก

Row count validation, freshness monitoring, null checks และ reconciliation กับ source data คือสิ่งที่ป้องกันไม่ให้ dashboard และ AI สูญเสียความน่าเชื่อถือเมื่อ sync ล้มเหลวแบบเงียบๆ

การสร้าง Analytics Layer

Dashboard ที่ดีไม่ได้เริ่มจาก 'เรามีข้อมูลอะไร' แต่เริ่มจาก 'ทีมนี้ต้องตัดสินใจอะไรทุกวัน' ถ้าตัวเลขเปลี่ยนแล้วไม่มี action ตามมา metric นั้นไม่ควรอยู่บนหน้าจอ

สำหรับธุรกิจ commerce หลายช่องทาง โครงสร้าง dashboard ที่ครอบคลุมส่วนใหญ่คือ Marketing, Sales และ Operations เพราะสามทีมนี้เป็นคนใช้ข้อมูลตัดสินใจแบบต่อเนื่องทุกวัน

DESIGN PRINCIPLE

หลักการที่สำคัญที่สุดคือเริ่มจากการตัดสินใจ ไม่ใช่เริ่มจาก data availability เพราะ dashboard ที่ทีมใช้ทุกวันต้องเป็น surface สำหรับ action ไม่ใช่เป็นแค่ report ที่ดูแล้วจบ

Marketing Dashboard

ใช้มองประสิทธิภาพการใช้จ่าย: ROAS, CPQL, CTR, conversion rate และการกระจาย budget ระหว่างช่องทาง

Sales Dashboard

ใช้มองการดำเนินงานรายได้: pipeline, lead-to-opportunity, deal progress, average order value และ quota attainment

Operations Dashboard

ใช้มองการปฏิบัติการจริง: inventory, stock turn, on-time delivery, lead time, shortage rate และจุดคอขวดของหน่วยงาน



KPI PRIORITISATION FRAMEWORK



ALIGNING DAILY DECISIONS WITH KEY PERFORMANCE INDICATORS



MARKETING SECTION

Daily Decisions	Supporting Metric
Decide Campaign Budget (Spend/leads)	ROAS, CPQL
Plan Content Calendar (Audience reach)	Traffic, Engagement
Optimize Ad Placements (Targeting)	CTR, Conversion Rate
Optimize Campaigns	Identify Key Gaps



SALES SECTION

Daily Decisions	Supporting Metric
Prioritize Leads (Contact attempts)	Lead to Ops
Schedule Client Meetings (Deal progress)	Pipeline Value, Deals Closed
Negotiate Terms (Discounting)	Average Order Value (AOV)
Forecast Month-end (Revenue)	Quota Attainment



OPERATIONS SECTION

Daily Decisions	Supporting Metric
Assign Production Tasks (Resources)	OEE, Capacity
Manage Inventory Levels (Replenishment)	Stock Turn, Shortage Rate
Optimize Shipping Routes (Delivery time)	On-time Delivery (OTD)
Reduce Process Waste (Lean flow)	Lead Time, Error Rate

AI Agent ทำงานจริงอย่างไร

AI agent ทำงานได้จริงก็ต่อเมื่อรู้ว่าตัวเองกำลังเข้าถึงข้อมูลแบบไหน และข้อมูลนั้นเชื่อถือได้หรือไม่ จุดนี้คือสิ่งที่หลายระบบข้ามไป ทำให้ AI ตอบคล้ายจะถูกแต่ใช้งานต่อไม่ได้

สำหรับงานธุรกิจจริง คุณต้องแยกให้ชัดว่าจะไรควรใช้ parametric knowledge, อะไรควรใช้ RAG และอะไรต้องใช้ tool calling กับข้อมูลสด

RAG WARNING

RAG มักล้มเหลวเมื่อ chunk ใหญ่เกินไป, embedding model จัดการภาษาไทยได้ไม่ดี หรือไม่มีข้อมูลที่เกี่ยวข้องใน knowledge base เลย ดังนั้นข้อมูลสดด้านตัวเลขควรใช้ tool call มากกว่าให้ RAG เตาแทน

Parametric Knowledge

เหมาะกับการร่าง content, reasoning ทั่วไป และ Q&A ที่ไม่อิงข้อมูลธุรกิจเฉพาะของคุณ

RAG

เหมาะกับ product knowledge, policy, FAQ, history และข้อมูล unstructured ที่ต้องดึงเอกสารเข้า prompt ตอน query

Tool Use / Function Calling

เหมาะกับตัวเลขสด, inventory ปัจจุบัน, dashboard query, API call และทุกอย่างที่ต้องอิง state ล่าสุดของธุรกิจ

✦ 5 ประเภท agent ที่ควรเริ่มคิดใน Phase 1

- ✓ Q&A agent สำหรับตอบคำถามจาก dashboard และ mart ที่ตรวจสอบแล้ว
- ✓ Insight agent สำหรับสรุป anomaly, trend และ bottleneck ที่เกิดขึ้นในแต่ละทีม
- ✓ Workflow agent สำหรับ trigger ขั้นตอนต่อเนื่อง เช่น follow-up, approval หรือ task routing
- ✓ Monitoring agent สำหรับเฝ้าดู sync failure, freshness issue และ threshold สำคัญ
- ✓ Multi-step agent สำหรับงานที่ต้องดึงข้อมูล วิเคราะห์ และตัดสินใจหลายรอบก่อนตอบ

การประเมิน Tech Stack แต่ละ Layer

การเลือก stack ที่ดีสำหรับบริษัทนี้ไม่ได้อยู่ที่ตัวไหนดังที่สุด แต่อยู่ที่ว่าใครเป็นเจ้าของข้อมูล ขยายต้นทุนอย่างไร และทีมของคุณพร้อมรับ maintenance ระดับไหน

สำหรับธุรกิจไทยที่มีข้อมูลลูกค้า การเงิน และการดำเนินงานอยู่ในระบบของตัวเอง แนวทาง open-source self-hosted มักเป็น default ที่ปลอดภัยกว่าในระยะยาว เพราะไม่ lock-in และ ควบคุม data sovereignty ได้ชัด

SELECTION RULES

- ✓ Data sovereignty มาก่อน convenience เมื่อข้อมูลมีความอ่อนไหวหรือมีข้อกำหนดทางธุรกิจ
- ✓ เลือก SaaS เมื่อ time-to-value สำคัญกว่า customization และทีมไม่พร้อมดูแล infrastructure
- ✓ ตั้ง image version, backup, monitoring และ secret management ตั้งแต่วันแรกเพื่อไม่ให้ infra สะสมความเสี่ยงใดๆ

AI Interface

Open WebUI เป็นหน้าใช้งานเดียวสำหรับทั้งทีม และ route ไปยัง model provider หลายเจ้าได้

Model Router

LiteLLM ใช้ควบคุม routing, cost cap และการเลือก model ตาม use case

Warehouse

ClickHouse เหมาะกับ analytical workload นึก ส่วน PostgreSQL เหมาะกับ operational state และ workflow

Ingestion

Airbyte เหมาะกับ connector เชิงมาตรฐาน แต่บางจุดยังต้องเสริมด้วย Python script หรือ scheduled job

Vector Search

pgvector เหมาะเมื่ออยากให้ vector search อยู่ใกล้ operational data และไม่ยากแทน stack โดยไม่จำเป็น

IMPLEMENTATION

การสร้างแบบเป็นรายเฟส

ลำดับการติดตั้งที่ดีคืออย่าเริ่มเฟสใหม่จนกว่าเฟสก่อนหน้าจะ validate แล้ว เพราะต้นทุนของการข้าม validation มักสูงกว่าการทำซ้ำอย่างมีวินัย



DATA AUDIT WORKSHEET

**A detailed review of data assets, sources, and management*

แหล่งข้อมูล Data Source	รูปแบบ Format	เจ้าของ Owner	ความถี่ Frequency	
☒ CRM ฐานข้อมูลลูกค้า Active Inactive	Structured โครงสร้าง	Marketing การตลาด Role	Daily รายวัน	☒ Audit Complete
☐ ERP ระบบวางแผนทรัพยากร	Structured ไม่มีโครงสร้าง	Finance การเงิน Role	Weekly รายสัปดาห์	☐ Needs Review
☐ Website Analytics วิเคราะห์เว็บไซต์	Unstructured ไม่มีโครงสร้าง	IT เทคโนโลยีสารสนเทศ Role	Monthly รายเดือน	☒ Up to Date
☐ Surveys แบบสำรวจ Active Inactive	Mixed ผสม	Operations ฝ่ายปฏิบัติการ	Real-time เรียลไทม์	☐ -
☐ Third-Party Data ข้อมูลภายนอก	   	Product ฝ่ายผลิตภัณฑ์ Product	Quarterly รายไตรมาส	☐ -

CREATED BY DATA ANALYTICS TEAM



เฟส 1 – Audit และสถาปัตยกรรมข้อมูล

สัปดาห์ 1-2

สรุปรายการแหล่งข้อมูล ออกแบบ schema, grain, naming และระบุ ingestion strategy ของแต่ละแหล่งให้เรียบร้อยก่อน build อะไรจริง

เฟส 2 – Infrastructure และ Ingestion

สัปดาห์ 2-4

deploy service หลัก ตั้งค่า network, secrets, backup, monitoring และเริ่มโหลดข้อมูลจากแหล่งสำคัญเข้าระบบ

เฟส 3 — Transformation และ Data Mart

สัปดาห์ 4–6

normalize ข้อมูลจาก raw ไป staged และสร้าง mart ที่พร้อมให้ dashboard กับ AI query ใช้งานได้จริง

เฟส 4 — Dashboard Build และ Review

สัปดาห์ 6–8

สร้าง dashboard ตามการตัดสินใจของแต่ละทีม ตรวจสอบ metric สำคัญกับ stakeholder และทำ reconciliation กับ source data

เฟส 5 — AI Agent Deployment

สัปดาห์ 8–10

เชื่อม agent เข้ากับ mart, tool function และ workflow ที่พร้อมใช้งานจริง พร้อม guardrail, logging และ feedback loop

Data Foundation

- ✓ audit แหล่งข้อมูลครบ พร้อม owner, connection type และ known gaps
- ✓ กำหนด grain ของทุก fact table ชัดเจนว่า 1 row แทนอะไร
- ✓ ตกลงนิยาม revenue, customer identity และ attribution policy แล้ว

Infrastructure

- ✓ service ทุกตัวรันใน Docker พร้อม pinned image version
- ✓ secrets ไม่อยู่ใน plain text และมี backup/restore test แล้ว
- ✓ monitoring, alerting และ disk/memory thresholds ถูกตั้งค่าครบ

ก่อน Dashboard Sign-off

- ✓ revenue reconciliation กับ platform อยู่ในกรอบที่ยอมรับได้
- ✓ row count, null check และ freshness check ผ่านสำหรับ connector สำคัญ
- ✓ อย่างน้อย 3 metric ถูก verify โดย business stakeholder กับ source data

ก่อน Agent Go-Live

- ✓ tool function สำคัญมี unit test และ historical validation
- ✓ agent ตอบ query หลักตรงกับ dashboard และ source data
- ✓ มี hallucination guardrail, log และ feedback loop สำหรับการปรับ prompt กับข้อมูล

worksheet และ framework ที่ควรใช้คู่กับการติดตั้ง

สอง artifacts ที่ช่วยให้ implementation ไม่หลุด scope คือ worksheet สำหรับ audit แหล่งข้อมูล และ framework สำหรับจัดลำดับ KPI ตามการตัดสินใจของแต่ละทีม


Data Source Audit Worksheet

ใช้เก็บรายการแหล่งข้อมูล format, owner, frequency และสถานะ readiness ก่อนเริ่ม build จริง



DATA AUDIT WORKSHEET

**A detailed review of data assets, sources, and management*


แหล่งข้อมูล Data Source	รูปแบบ Format	เจ้าของ Owner	ความถี่ Frequency	สถานะ Status
☒ CRM ฐานข้อมูลลูกค้า Active Inactive	Structured โครงสร้าง	Marketing การตลาด Role	Daily รายวัน	☒ Audit Complete
☐ ERP ระบบวางแผนทรัพยากร	Structured ไม่มีโครงสร้าง	Finance การเงิน Role	Weekly รายสัปดาห์	☐ Needs Review
☐ Website Analytics วิเคราะห์เว็บไซต์	Unstructured ไม่มีโครงสร้าง	IT เทคโนโลยีสารสนเทศ Role	Monthly รายเดือน	☒ Up to Date
☐ Surveys แบบสำรวจ Active Inactive	Mixed ผสม	Operations ฝ่ายปฏิบัติการ Product	Real-time เรียลไทม์	☐ -
☐ Third-Party Data ข้อมูลภายนอก		Product ฝ่ายผลิตภัณฑ์	Quarterly รายไตรมาส	☐ -

CREATED BY DATA ANALYTICS TEAM



KPI Prioritisation Framework

ใช้จัดลำดับ metric ตามการตัดสินใจของทีม marketing, sales และ operations เพื่อไม่ให้ dashboard กลายเป็น report ที่ไม่มี action



ขั้นตอนถัดไป

ถ้าพร้อมจะเริ่ม Phase 1 แบบจริงจัง จอง discovery call ได้เลย

เราจะช่วย map data landscape ปัจจุบันของคุณ ระบุการเชื่อมต่อที่มีมูลค่าสูงสุด
ก่อน และวาง rollout ที่เหมาะกับธุรกิจคุณจริง

- ✓ Dashboard สดถึงข้อมูลทุกช่องทาง
- ✓ AI Agent ตอบคำถามจากข้อมูลธุรกิจจริง
- ✓ ระบบ Workflow อัตโนมัติทำงานจริง
- ✓ แผนการติดตั้งเฉพาะสำหรับธุรกิจคุณ

ถ้าอยากกรอกข้อมูลเชิงลึกก่อนคุย

เปิดฟอร์ม demo แบบเต็ม →



เลือกเวลาที่สะดวก

เลือกวันเวลาจากปฏิทินด้านล่าง เราจะยืนยันทางอีเมล